




Folder



e-mail



Internet



Computer




Final Project


NLP

KELOMPOK 5





PENGARUH CHAIN- OF-THOUGHTS TERHADAP PENALARAN MATEMATIKA LLM



Latar Belakang

Pendidikan matematika di Indonesia memiliki kurikulum yang terstruktur dari tingkat SMA hingga ujian masuk perguruan tinggi nasional (SNBT) dan olimpiade sains (OSN/KSN), namun belum ada model bahasa berbasis open-weight yang secara khusus di-fine-tune untuk menangani soal-soal matematika berbahasa Indonesia. Model multilingual seperti Qwen2.5-7B-Instruct dapat menyelesaikan beberapa soal matematika Indonesia secara zero-shot, tetapi sering mengalami kesulitan dalam memahami kosakata, kerangka soal, dan format jawaban yang umum digunakan dalam kurikulum Indonesia. Penelitian terkini menunjukkan bahwa pendekatan chain-of-thought (CoT) prompting dan knowledge distillation dari model teacher yang kuat dapat meningkatkan kemampuan reasoning model bahasa secara dramatis, sebagaimana ditunjukkan oleh OpenMathInstruct-1 (Toshniwal et al., 2024) dan studi LIMO yang membuktikan bahwa fine-tuning pada dataset kecil berkualitas tinggi dapat menghasilkan performa kompetitif (Ye et al., 2025).

Namun, mayoritas penelitian ini berfokus pada bahasa Inggris, sementara efektivitas pendekatan serupa pada bahasa Indonesia terutama dengan model berukuran sangat kecil seperti 0.5B parameter belum banyak dieksplorasi. Final Project ini bertujuan mengisi kesenjangan tersebut dengan membangun model bahasa Indonesia berukuran 0.5B parameter melalui fine-tuning pada data CoT yang dihasilkan dari teacher model DeepSeek-R1-Distill-Qwen2.5-7B, dengan mengeksplorasi seluruh pipeline mulai dari konstruksi dataset berkualitas tinggi melalui scraping soal-soal ujian nasional (UN/SNBT/OSN), sintesis solusi CoT berbahasa Indonesia, hingga evaluasi komprehensif, sehingga diharapkan dapat memberikan kontribusi teoretis tentang efektivitas knowledge distillation pada bahasa non-Inggris dengan model kecil, serta kontribusi praktis berupa model lightweight yang dapat mendukung pembelajaran matematika di Indonesia.



2
×

RUMUSAN MASALAH

5


Bagaimana membuat dataset soal matematika berbahasa Indonesia yang bersih dan bebas duplikasi melalui proses scraping?


Bagaimana menghasilkan solusi Chain-of-Thought (CoT) berkualitas tinggi untuk setiap soal menggunakan teacher model dan seberapa besar proporsi solusi yang lolos validasi format maupun kebenaran jawaban?


Apakah fine-tuning Qwen2.5-0.5B-Base menggunakan data CoT hasil distilasi dari DeepSeek-RL-Distill-Qwen2.5-7B dapat meningkatkan kemampuan mathematical reasoning model dalam bahasa Indonesia, dibandingkan dengan model baseline tanpa fine-tuning?


Seberapa baik performa model hasil fine-tuning ketika dievaluasi pada metric pass@1 - pass@4 dan, maj@4





TUJUAN


1. Membuat dataset soal matematika yang bersih dan bebas duplikasi
2. Menghasilkan data test untuk tiap pasangan soal dan solusi dari Chain-of-Thought (CoT)
3. Melatih model Qwen2.5-0.5B-Base menggunakan data CoT yang dihasilkan dan mengukur peningkatan kemampuan mathematical reasoning dalam bahasa indonesia dibandingkan baseline
4. Membandingkan performa model sebelum dan sesudah fine-tuning pada metric



Grouping Symbols



Multiplication




Division



Addition



Subtraction



MANFAAT


TEORITIS

1. Memberikan kontribusi dataset soal matematika berbahasa Indonesia yang dapat digunakan untuk penelitian selanjutnya
2. Menambah pemahaman tentang seberapa efektif pendekatan knowledge distillation via CoT ketika diterapkan pada bahasa selain Inggris.

PRAKTIS

1. Menghasilkan model berukuran kecil (0.5B parameter) yang mampu menyelesaikan soal matematika dalam Bahasa Indonesia
2. Pipeline yang dibangun bisa diadaptasi oleh peneliti lain untuk keperluan serupa di masa mendatang





DATASET

Soal OSN Matematika SMA/MA Tingkat Kabupaten/Kota

**<https://www.defantri.com/2013/04/materi-soal-osk-osp-matematika-sma.html>*

SEDANG DIPROSES



N

L

P

Gap Analysis	
Penelitian Terdahulu	Gap Analysis
Hendrycks et al. (2021) Meneliti mengenai Benchmark MATH untuk evaluasi mathematical reasoning	Hanya membahas evaluasi, tidak membahas cara melatih modelnya
Wei et al. (2022) meneliti mengenai teknik Chain-of-Thought prompting untuk meningkatkan kemampuan reasoning model bahasa.	Hanya efektif pada model berukuran sangat besar (100B+ parameter), belum mengeksplorasi transfer kemampuan ini ke model yang lebih kecil melalui distilasi.
Kim et al. (2023) meneliti mengenai diversifikasi jalur penalaran pada math word problems untuk meningkatkan akurasi model.	Hanya menggunakan dataset berbahasa Inggris dan belum membahas bagaimana strategi ini diterapkan dalam pembuatan data latih untuk model kecil.
Guo et al. (2025) meneliti mengenai distilasi kemampuan reasoning dari model besar ke model kecil menggunakan data CoT.	Data distilasi yang digunakan sepenuhnya berbahasa Inggris, belum mencakup soal matematika berbahasa Indonesia.

()

Grouping Symbols

×

Multiplication

÷

Division

+

Addition

-

Subtraction



Metode



Data collection. Soal dikumpulkan dari ujian nasional SMA, SNBT, olimpiade matematika, dan situs edukasi seperti Zenius dan Ruangguru. Sumber berupa PDF dan halaman web yang diekstrak menjadi teks dengan notasi matematika LaTeX. Target sekitar 1.000 sampai 2.000 soal.

preprocessing. Soal yang terkumpul disaring untuk memastikan hanya soal yang lengkap, berbahasa Indonesia, dan memiliki jawaban terverifikasi yang masuk ke tahap selanjutnya. Penyaringan mencakup penghapusan duplikat dan pengecekan terhadap benchmark evaluasi agar tidak terjadi kebocoran data. Target setelah penyaringan sekitar 1.200 soal bersih.

CoT synthesis dan training. Setiap soal dibuatkan solusi langkah demi langkah menggunakan teacher model. Solusi yang jawabannya benar digunakan untuk melatih Qwen2.5-0.5B melalui supervised fine-tuning. Model hanya belajar dari bagian solusi sehingga terbiasa menghasilkan penyelesaian yang terstruktur.

Evaluasi. Model dievaluasi pada 150 soal. Metrik utama adalah pass@1-pass@4 dan maj@4 . Hasil dibandingkan terhadap beberapa model baseline yang dijalankan tanpa fine-tuning untuk menunjukkan efek dari pelatihan pada data matematika Indonesia.


Data collection

Preprocessing

CoT synthesis

Fine-tuning


Evaluation



Grouping Symbols



Multiplication



Division



Addition




Subtraction




SKENARIO

1. perbandingan metode preprocess dataset yang terbaik
2. perbandingan metode CoT
3. membandingkan hasil CoT vs non-CoT
4. membandingkan terhadap model yang tidak di finetune



Bahan Penelitian

- *Kaggle T4*
- *5050 VRAM 8, 32GB RAM*
- *4060 VRAM 8, 20GB RAM*
- *4060 VRAM 8, 16GB RAM*
- *3050 VRAM 6, 12GB RAM*



Urutan Pelaksanaan

Week 1

- Set up environment, install tools, write PDF extractor
- Scrape and extract problems from all sources

Week 2

- Run classification filters; extract/align answer keys
- Deduplication; create train/val split; generate CoT solutions

Week 3

- Filter CoT solutions; convert to training format
- Run SFT Round 1; monitor training loss and val accuracy

Week 4

- Full evaluation: pass@1, maj@4, all baselines
- Ablations; error analysis; write-up
- Final report; slides; (optional) Gradio demo

REFERENCES


1. Mingyu Zheng, Hao Yang, Wenbin Jiang, Zheng Lin, Yajuan Lyu, Qiaoqiao She, and Weiping Wang. 2023. Chain-of-Thought Reasoning in Tabular Language Models. In Findings of the Association for Computational Linguistics: EMNLP 2023, pages 11006–11019, Singapore. Association for Computational Linguistics.
2. Jb. Kim, Hazel Kim, Joonghyuk Hahn, and Yo-Sub Han. 2023. ATHENA: Mathematical Reasoning with Thought Expansion. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, pages 16315–16327, Singapore. Association for Computational Linguistics.
3. Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. 2021. Measuring Mathematical Problem Solving With the MATH Dataset. In Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks, pages 1–24, Virtual. Curran Associates, Inc.
4. Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V Le, and Denny Zhou. 2022. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. In Advances in Neural Information Processing Systems, volume 35, pages 24824–24837. Curran Associates, Inc.
5. DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, et al. 2025. DeepSeek-RL: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. Nature. <https://doi.org/10.1038/s41586-025-09422-z>
6. Gitman, Igor. 2025. ALMO-2 Winning Solution: Building State-of-the-Art Mathematical Reasoning Models with OpenMathReasoning dataset. HuggingFace




Search




9:57 am
24/07/2025




Folder



e-mail




Internet



Computer

Thank You!



LOG OUT



Search



9:57 am
24/07/2025